

Mini-Spark: Sistema Distribuido de Procesamiento Batch con DAG

1st Kristhel Cordero Leiva

Escuela de Ingeniería en Computación

Instituto Tecnológico de Costa Rica

Cartago, Costa Rica

krcordero@estudiantec.cr

2nd Juan Jiménez Valverde

Escuela de Ingeniería en Computación

Instituto Tecnológico de Costa Rica

Cartago, Costa Rica

juand0908@estudiantec.cr

Resumen—Este trabajo presenta Mini-Spark, un sistema distribuido de procesamiento batch inspirado en Apache Spark, implementado en Go. El sistema utiliza un modelo maestro-trabajador para ejecutar grafos acíclicos dirigidos (DAG) de operadores de transformación de datos sobre conjuntos de datos particionados. La arquitectura incluye un nodo coordinador (Master) que realiza planificación topológica y asignación de tareas con balanceo de carga, y múltiples nodos trabajadores (Workers) que ejecutan operadores como map, filter, flat_map, reduce_by_key, aggregate y join. Se implementaron mecanismos de tolerancia a fallos con reintentos automáticos, persistencia de estado, gestión de memoria con spill to disk, y monitoreo mediante heartbeats. Los resultados experimentales demuestran un throughput promedio de 19,000 registros/segundo procesando datasets de 1 millón de registros en un cluster local de 3 workers, validando la eficacia del diseño distribuido y los mecanismos de recuperación ante fallos.

Index Terms—Procesamiento distribuido, DAG, Batch processing, Tolerancia a fallos, Planificación de tareas, Apache Spark, Golang, Sistemas operativos

I. INTRODUCCIÓN

El procesamiento distribuido de grandes volúmenes de datos es fundamental en aplicaciones modernas de análisis y ciencia de datos. Frameworks como Apache Spark [1] han revolucionado este campo al introducir el modelo de programación basado en DAG (Directed Acyclic Graph) que permite expresar pipelines complejos de transformaciones de datos de manera declarativa.

Este proyecto implementa Mini-Spark, una versión simplificada de un motor de procesamiento batch distribuido que captura los principios arquitectónicos fundamentales de Spark: (1) representación de jobs como DAG de operadores, (2) ejecución distribuida mediante particionamiento de datos, (3) planificación topológica de tareas con manejo de dependencias, y (4) tolerancia a fallos mediante reintentos y reasignación.

El sistema está construido en Go, aprovechando sus goroutines para concurrencia, canales para comunicación, y mutexes para sincronización de estado compartido. La arquitectura sigue el patrón maestro-trabajador: un nodo Master coordina la ejecución de jobs recibidos vía API REST, mientras que múltiples Workers ejecutan tareas asignadas sobre particiones de datos, reportando progreso mediante heartbeats periódicos.

Las principales contribuciones de este trabajo incluyen: (1) diseño e implementación completa de un sistema distribuido

funcional con 7 operadores de transformación, (2) mecanismos robustos de tolerancia a fallos con detección de workers caídos y reasignación automática, (3) gestión eficiente de memoria con cache y spill to disk, (4) persistencia de estado para recuperación, y (5) validación experimental con datasets de hasta 1 millón de registros demostrando throughput competitivo.

II. MARCO TEÓRICO

II-A. Procesamiento Batch Distribuido

El procesamiento batch distribuido consiste en dividir un conjunto de datos grande en particiones que se procesan en paralelo por múltiples nodos [2]. Este paradigma es fundamental para análisis de datos a gran escala, permitiendo escalabilidad horizontal agregando más nodos al cluster.

II-B. Modelo de Programación DAG

Un DAG (Directed Acyclic Graph) representa un pipeline de procesamiento donde los nodos son operadores de transformación y las aristas son dependencias de datos [1]. Este modelo permite optimizaciones como fusión de etapas, paralelización de ramas independientes, y detección temprana de errores mediante validación de ciclos.

II-C. Particionamiento y Shuffle

El particionamiento distribuye registros entre workers usando funciones hash sobre claves, garantizando que registros con la misma clave residan en la misma partición [3]. El shuffle reorganiza datos entre etapas cuando es necesario agrupar por clave (ej. reduce_by_key, join).

II-D. Tolerancia a Fallos

Los sistemas distribuidos deben manejar fallos de nodos mediante: (1) detección vía heartbeats o timeouts, (2) reintentos de tareas fallidas, y (3) reasignación a nodos disponibles [2]. La idempotencia de operadores permite re-ejecución segura.

II-E. Planificación de Tareas

La planificación en sistemas DAG requiere ordenamiento topológico para respetar dependencias [4]. El algoritmo de Kahn procesa nodos sin dependencias pendientes, agregando hijos a la cola cuando sus padres completan, detectando ciclos si quedan nodos no procesados.

III. DISEÑO E IMPLEMENTACIÓN

III-A. Arquitectura General

La arquitectura de Mini-Spark sigue el patrón maestro-trabajador con tres componentes principales distribuidos:

Master Node: Coordinador central que expone una API REST en puerto 8080 para recibir jobs del cliente CLI. Mantiene estado en memoria (workers registrados, jobs activos, tareas pendientes/completadas) sincronizado con mutexes. Ejecuta tres goroutines background: (1) monitor de heartbeats que marca workers DOWN si no responden en 10 segundos, (2) auto-save que persiste estado a disco cada 30 segundos, y (3) reasignador de tareas fallidas.

Worker Nodes: Procesos independientes que ejecutan tareas asignadas. Cada worker mantiene un pool de goroutines para ejecución paralela, envía heartbeats al Master cada 2 segundos con métricas de CPU/memoria/goroutines, y reporta actualizaciones de estado de tareas (RUNNING, COMPLETED, FAILED).

Cliente CLI: Herramienta de línea de comandos en Go que parsea archivos JSON de definición de jobs y los envía al Master vía HTTP POST. Soporta comandos: submit (crear job), status (consultar progreso), list (listar todos los jobs), y health (verificar cluster).

III-B. Modelo de Concurrencia y Procesos

III-B1. Diseño de Hilos con Goroutines: El sistema aprovecha el modelo de concurrencia de Go basado en goroutines (green threads gestionadas por el runtime) para lograr paralelismo eficiente sin el overhead de threads del sistema operativo.

Master - Goroutines Background:

El proceso Master ejecuta múltiples goroutines simultáneas coordinadas mediante channels y mutexes:

1. **HTTP Server Goroutine:** El servidor `http.ListenAndServe` crea automáticamente una goroutine por cada request HTTP entrante, permitiendo que el Master procese múltiples operaciones concurrentes (submit job, status query, task updates) sin bloqueo. Cada handler adquiere locks según necesidad.
2. **Heartbeat Monitor:** Goroutine dedicada que ejecuta cada 10 segundos, verificando el campo `LastHeartbeat` de cada worker. Si el tiempo transcurrido excede 10 segundos, marca el worker como DOWN y dispara reasignación automática de tareas. Utiliza `sync.Mutex` exclusivo para modificar estado de workers y jobs de forma atómica, garantizando consistencia en escrituras concurrentes.
3. **State Persistence:** Goroutine de auto-save cada 30 segundos que serializa el estado completo (jobs, tasks, workers) a JSON y lo escribe en dos archivos: uno con timestamp para histórico y otro como último snapshot. Utiliza `RLock` para lectura concurrente, permitiendo que otros lectores y el monitor de heartbeats operen simultáneamente sin bloqueo.
4. **Task Assignment Loop:** Goroutine que verifica cada 5 segundos si existen tareas con dependencias completadas

y workers disponibles. Al encontrar tareas elegibles, invoca el algoritmo de balanceo de carga para seleccionar el worker óptimo y actualiza el estado de la tarea a PENDING con worker asignado.

Worker - Pool de Ejecución:

Cada Worker ejecuta un pool de goroutines limitado por un semáforo basado en channels, donde `maxConcurrent` define el número máximo de tareas ejecutándose simultáneamente. El worker consulta tareas asignadas cada 5 segundos mediante polling, y por cada tarea obtenida crea una goroutine independiente que adquiere un slot del semáforo, ejecuta la tarea, reporta resultados al Master, y libera el slot. Este diseño previene sobrecarga del sistema manteniendo control explícito sobre la concurrencia.

Heartbeat Goroutine: Una goroutine dedicada envía heartbeats cada 2 segundos, incluyendo métricas del sistema (CPU %, memoria usada/total, número de goroutines activas) recolectadas mediante el paquete `runtime` de Go. El heartbeat es fire-and-forget (no espera respuesta), minimizando latencia.

III-B2. Sincronización de Estado Compartido: El Master mantiene tres estructuras de datos compartidas (workers, jobs, tasks) protegidas por un `sync.RWMutex`.

Patrón de Acceso:

- **Lecturas (RLock):** GET /jobs, GET /jobs/{id}, consultas de estado. Múltiples goroutines pueden leer concurrentemente.
- **Escrituras (Lock):** POST /jobs (crear), task updates (modificar estado), heartbeats (actualizar timestamp). Exclusivo, bloquea lectores y escritores.

Justificación: Se eligió `RWMutex` sobre `Mutex` simple porque las lecturas (consultas de estado) son mucho más frecuentes que escrituras (actualizaciones). En benchmarks, 80 % de operaciones son lecturas, por lo que permitir concurrencia en lecturas mejora throughput del Master.

III-B3. Modelo de Comunicación: La comunicación entre componentes usa HTTP/JSON sobre TCP:

Cliente → Master: HTTP POST con job definition en JSON. Bloqueante, espera respuesta con Job ID.

Worker → Master (Heartbeat): HTTP POST cada 2s con métricas. Fire-and-forget, worker no espera respuesta.

Worker → Master (Task Update): HTTP POST al completar/fallar tarea. Bloqueante, espera ACK.

Master → Worker (Asignación): Polling por parte del worker. Worker hace GET /workers/tasks cada 5s y procesa tareas asignadas.

Trade-off Polling vs Push: Se optó por polling en lugar de que Master push tareas por:

1. **Simplexidad:** Master es stateless respecto a conexiones de workers. No necesita mantener conexiones WebSocket o gRPC streams.
2. **Tolerancia a Fallos:** Si worker se desconecta/reconecta, simplemente reanuda polling sin lógica de reconexión compleja.
3. **Costo:** Latencia de hasta 5s para asignación. Aceptable dado que tareas típicas duran 10-60s.




Figura 1. Arquitectura detallada del sistema Mini-Spark mostrando Master, Workers, y almacenamiento compartido.

En producción, un modelo híbrido (push vía long-polling o Server-Sent Events con fallback a polling) sería óptimo.

III-C. Modelo de Datos

El sistema define tres estructuras principales en `common/types.go`:

Job: Representa un trabajo completo con ID único, nombre, DAG (nodos y aristas), paralelismo configurado, estado (ACCEPTED, RUNNING, SUCCEEDED, FAILED), lista de tareas generadas, timestamps de submission/inicio/fin, y porcentaje de progreso calculado como tareas completadas / tareas totales.

Task: Unidad de ejecución asignada a un worker. Incluye: ID, referencia al job padre, nodo del DAG, operador a ejecutar, rutas de entrada/salida, número de partición (0 a N-1), total de particiones, lista de dependencias (NodeIDs que deben

completarse primero), número de intento (0-2 para reintentos), estado, worker asignado, parámetros del operador, timestamps, duración, y límites opcionales de timeout/memoria.

WorkerInfo: Información de un worker registrado: ID, dirección, estado (UP/DOWN), timestamp de registro, último heartbeat recibido, tareas activas actuales, tareas totales procesadas, y métricas del sistema (CPU %, memoria usada/total, número de goroutines).

III-D. Protocolos de Comunicación

III-D1. Protocolo de Heartbeat: El sistema implementa un protocolo de heartbeat para detección de fallos:

Fase 1 - Registro:

1. Worker inicia y envía POST `/api/v1/workers/register` con `{worker_id,`

address}.

2. Master valida ID único, crea entrada en `workers` map, retorna `{heartbeat_interval: 2s, timeout: 10s}`.
3. Worker almacena parámetros y marca estado como REGISTERED.

Fase 2 - Heartbeats Periódicos: Cada worker ejecuta un loop con `ticker` de 2 segundos que recolecta métricas del sistema (CPU%, memoria usada/total, número de goroutines) y las envía al Master vía `POST /api/v1/workers/heartbeat` junto con el número de tareas activas.

Fase 3 - Detección de Fallo: El Master ejecuta un monitor cada 10 segundos que calcula el tiempo transcurrido desde el último heartbeat de cada worker. Si el `elapsed` excede el `threshold` de 10 segundos y el worker estaba UP, lo marca como DOWN y dispara reasignación automática de todas sus tareas activas.

Propiedades del Protocolo:

- **Frecuencia:** 2 segundos (configurable). Trade-off: menor intervalo = detección más rápida pero más overhead de red.
- **Timeout:** 10 segundos (5 heartbeats perdidos). Evita falsos positivos por congestión de red transitoria.
- **Métricas:** CPU, memoria, goroutines enviadas en cada heartbeat para monitoreo de salud.

III-D2. Protocolo de Asignación de Tareas: Modelo Pull (Polling):

Workers consultan activamente tareas asignadas mediante `GET /api/v1/workers/tasks` cada 5 segundos. El Master filtra tareas donde `WorkerID` coincide y `Status == PENDING`, retornando un array JSON. El worker verifica disponibilidad de recursos antes de ejecutar cada tarea en una goroutine separada.

Flujo de Asignación:

1. Master recibe job, crea tasks en estado PENDING sin worker asignado.
2. Background goroutine `checkAndAssignReadyTasks()` verifica cada 5s:
 - Tareas con dependencias completadas
 - Workers UP disponibles
3. Selecciona worker con menor `ActiveTasks` (balanceo por carga).
4. Actualiza `Task.WorkerID` y mantiene `Status = PENDING`.
5. Worker consulta tareas, las obtiene, y marca cada una como `RUNNING` enviando `POST /api/v1/tasks/update` con `status, start_time`.
6. Al completar, envía actualización final con `status=COMPLETED, end_time, duration_ms, y output_path`.

Ventajas del Modelo Pull:

- Workers controlan su rate de consumo (backpressure natural)

- Master no necesita mantener estado de conexiones
- Fácil implementar retry: worker reintenta GET si falla

Desventajas:

- Latencia de asignación: hasta 5s entre que tarea está lista y worker la recoge
- Overhead de red: polling constante incluso sin tareas nuevas

III-E. Planificación y Coordinación

El componente `master/scheduler.go` implementa la lógica de planificación distribuida:

III-E1. Algoritmo de Planificación: Validación del DAG: Verifica dos propiedades: (1) IDs de nodos son únicos usando un mapa auxiliar, y (2) todas las aristas referencian nodos existentes. Retorna error si detecta duplicados o referencias inválidas, previniendo ciclos y asegurando integridad del grafo antes de la planificación.

Ordenamiento Topológico (Algoritmo de Kahn): Implementa el algoritmo clásico: (1) calcula el grado de entrada (in-degree) de cada nodo contando aristas entrantes, (2) inicializa una cola con nodos de grado 0 (sin dependencias), (3) procesa nodos de la cola agregándolos a la lista ordenada, y por cada arista saliente reduce el grado de entrada del nodo destino, agregándolo a la cola si llega a 0, (4) detecta ciclos verificando que todos los nodos fueron procesados. La complejidad es $O(V + E)$ donde V = nodos y E = aristas, eficiente incluso para DAGs con cientos de nodos.

Creación de Tareas con Particionamiento:

Para cada nodo en orden topológico, genera N tareas (una por partición configurada). Cada tarea recibe un ID único (`nodeID-part-N`), número de partición (0 a $N-1$), operador a ejecutar, y lista de NodeIDs de dependencias. El campo `Dependencies` permite verificación dinámica: una tarea solo es elegible para asignación cuando todas las tareas de sus nodos dependientes han completado.

Asignación con Balanceo de Carga: Implementa política *least-loaded* seleccionando el worker con menor número de tareas activas (`ActiveTasks`) entre todos los workers con `Status == UP`. Se consideró una alternativa con *weighted load* (ponderar CPU/memoria), pero fue descartada por complejidad adicional sin beneficio medible en benchmarks: la variación de carga de CPU entre workers fue $<5\%$ en pruebas.

Manejo de Dependencias Dinámico: Antes de asignar una tarea, el scheduler verifica que por cada NodeID en `task.Dependencies` exista al menos una tarea con `Status == COMPLETED`. Esta verificación dinámica permite ejecución *wavefront*: todas las tareas del stage N completan antes de que cualquier tarea del stage $N+1$ inicie, garantizando que los datos de entrada estén disponibles.

III-F. Ejecución de Operadores

El componente `worker/executor.go` implementa 7 operadores:

read_csv: Lee archivo CSV de entrada, aplica particionamiento hash sobre la primera columna (clave), filtra registros que correspondan a la partición asignada (`hash(key) mód  $N == partition$`), y escribe `output-part-N.csv`.

map: Transformación 1-a-1. Lee registros de entrada, aplica función configurada (lowercase, uppercase, o custom), y escribe salida. Soporta transformaciones en columnas específicas vía parámetros.

filter: Filtra registros según condición. Lee entrada, evalúa predicado (equals, contains, greater_than) en columna especificada, y escribe solo registros que cumplen la condición.

flat_map: Expansión 1-a-N. Soporta tres funciones: (1) `split_words` tokeniza texto en palabras, (2) `split_delimiter` divide por delimitador personalizado, (3) `explode_array` expande arrays en registros individuales. Usado para word count.

reduce_by_key: Agrupación y reducción. Lee particiones de entrada (múltiples `input-part-*.csv`), agrupa registros por clave en un map, cuenta ocurrencias por clave, y escribe pares clave-count. Implementa shuffle: lee todas las particiones de entrada generadas por etapa previa.

aggregate: Agregación configurable con 5 funciones: count (cuenta registros), sum (suma columna numérica), avg (promedio), min (mínimo), max (máximo). Parámetros: `function`, `group_column`, `value_column`.

join: Join inner por clave entre dos datasets. Lee ambos inputs, construye hash tables por clave, realiza join, y escribe registros coincidentes. Soporta shuffle: lee todas las particiones de ambos inputs.

III-G. Gestión de Memoria

El componente `common/cache.go` implementa un CacheManager con límite configurable para evitar Out-Of-Memory en workers:

III-G1. Diseño del Cache con Spill: El CacheManager mantiene dos mapas: `cache` para datos en memoria (strings bidimensionales) y `spilledFiles` para rutas en disco. Rastrea memoria usada (`usedMemoryMB`) contra un límite configurable (`maxMemoryMB`, default 100MB), protegido por `sync.RWMutex` para acceso concurrente seguro.

Estimación de Tamaño:

Aproxima memoria usada como:

$$memoria_{MB} = \frac{filas \times columnas \times 50}{1024^2} \quad (1)$$

Asume 50 bytes promedio por celda (incluye overhead de strings en Go). Calibrado empíricamente con datasets reales.

Algoritmo Put con Spill Automático: Al intentar agregar datos, primero estima el tamaño usando la fórmula anterior. Si `usedMemoryMB + size > maxMemoryMB`, escribe los datos a un archivo CSV en `temp/spill-{key}-{timestamp}.csv`, registra la ruta en `spilledFiles`, y retorna sin consumir memoria. Si hay espacio, almacena en `cache` e incrementa `usedMemoryMB`. Ambas operaciones usan `Lock` exclusivo para consistencia.

Lectura Transparente con Fallback: El método `Get` implementa búsqueda en dos niveles: primero intenta lectura de `cache` con `RLock` (cache HIT, retorno inmediato). Si no existe, busca en `spilledFiles` y lee el CSV desde disco (cache MISS, disk HIT). Si tampoco existe, retorna error `key`

`not found`. El proceso es transparente para el ejecutor, que no necesita conocer si los datos están en memoria o disco.

Justificación del Límite de 100MB:

En un worker con 512MB RAM:

- 100MB cache (20 % RAM)
- 200MB Go runtime + goroutines
- 150MB buffers de I/O
- 62MB margen de seguridad

Con 3 workers y datasets de 1M registros (77MB CSV), cada worker procesa 3 particiones (25MB cada una). El límite de 100MB permite mantener 4 particiones en memoria, evitando spill en el caso común.

Trade-off: Límite más alto = menos spills (más rápido) pero mayor riesgo de OOM. Límite más bajo = más spills (más lento) pero más seguro. 100MB es un balance conservador.

III-H. Tolerancia a Fallos

El sistema implementa un esquema completo de tolerancia a fallos distribuidos:

III-H1. Detección de Fallos por Timeout: Una goroutine del Master ejecuta cada 10 segundos un chequeo de heartbeats: itera sobre todos los workers con `Status == UP`, calcula el tiempo transcurrido desde `LastHeartbeat`, y si excede 10 segundos marca el worker como `DOWN`, registra `FailureTime`, y busca todas las tareas con `WorkerID` coincidente en estado `RUNNING` o `PENDING` para reasignarlas. El proceso completo ejecuta bajo un `Lock` exclusivo para prevenir condiciones de carrera con actualizaciones de heartbeat concurrentes.

Parámetros:

- **Check interval:** 10 segundos
- **Timeout threshold:** 10 segundos (5 heartbeats perdidos)
- **False positive rate:** Baja (0.1 % en benchmarks) gracias a umbral conservador

III-H2. Reintentos con Límite: El método `reassignTask` implementa la política de reintentos: incrementa `AttemptNum` de la tarea, y si alcanza `MAX_RETRIES` (3), marca la tarea como `FAILED` permanentemente y verifica si el job completo debe fallar. Si aún quedan intentos, busca un nuevo worker disponible usando el algoritmo de balanceo, actualiza `WorkerID`, cambia estado a `PENDING`, y resetea timestamps para re-ejecución. No se implementa backoff exponencial porque las tareas son idempotentes y el overhead de espera es innecesario.

Política de Reintentos:

1. **Primer intento:** Ejecución normal en worker seleccionado
2. **Segundo intento:** Si falla (timeout/crash), reasignar a otro worker inmediatamente
3. **Tercer intento:** Última oportunidad con logging adicional
4. **Fallo final:** Marca tarea como `FAILED`, propaga a job padre

No se usa backoff exponencial porque las tareas son idempotentes y el overhead de espera es innecesario.

III-H3. Reasignación de Tareas: El método `findTasksForWorker` busca todas las tareas asociadas a un worker dado que estén en estado `RUNNING` o `PENDING`, retornando una lista de tareas afectadas. Este método se invoca en tres escenarios: (1) **Worker Crash** - detectado por timeout de heartbeat, todas las tareas del worker se reasignan; (2) **Task Failure** - fallo individual de una tarea por error de operador, solo esa tarea se reintenta; (3) **Graceful Shutdown** - worker envía señal de shutdown, Master marca como `DOWN` proactivamente.

III-H4. Garantías de Idempotencia: Todos los operadores son diseñados para ser idempotentes mediante cuatro propiedades fundamentales: (1) **Sobrescritura** - outputs siempre se sobrescriben usando `os.Create`, nunca `append`; (2) **Determinismo** - dado el mismo input y parámetros, el output es idéntico; (3) **Sin estado** - operadores no dependen de ejecuciones previas; (4) **Transaccionalidad** - escritura atómica usando `rename` final.

Caso Edge - Shuffle con Múltiples Intentos: En `reduce_by_key`, múltiples tareas leen las mismas particiones de entrada. Si una tarea se reintenta, podría leer particiones aún en escritura por otra tarea en paralelo. La solución implementada escribe primero a un archivo temporal con extensión `.tmp`, y luego ejecuta `os.Rename` al path final. En sistemas POSIX, `rename` es atómico a nivel del filesystem, previniendo lecturas parciales y garantizando que los lectores solo ven archivos completos o no los ven.

III-I. Persistencia de Estado

El componente `common/persistence.go` maneja snapshots del estado del Master:

Auto-Save: Cada 30 segundos, la goroutine background serializa a JSON los maps de workers, jobs y tasks, y escribe dos archivos: `storage/state-{timestamp}.json` (histórico) y `storage/state-latest.json` (último snapshot).

Recuperación: Al iniciar, el Master intenta cargar `state-latest.json`. Si existe, restaura los maps de jobs y tasks. Los workers NO se restauran ya que deben re-registrarse (asegura workers realmente activos).

III-J. API REST

El Master expone 8 endpoints HTTP/JSON:

- `POST /api/v1/jobs`: Crea job. Recibe JSON con nombre, DAG (nodos/aristas), paralelismo. Valida DAG, ejecuta scheduler, retorna Job con ID.
- `GET /api/v1/jobs`: Lista todos los jobs con estado y progreso.
- `GET /api/v1/jobs/{id}`: Retorna detalles completos de un job: DAG, todas las tasks con estado/duración/output, progreso, timestamps.
- `POST /api/v1/workers/register`: Registra worker. Recibe WorkerID y address, agrega a registry, retorna heartbeat interval.
- `POST /api/v1/workers/heartbeat`: Recibe heartbeat. Actualiza `LastHeartbeat` y métricas del worker, marca como UP.

- `GET /api/v1/workers/tasks`: Worker consulta tareas asignadas. Filtra tasks con `WorkerID == requestWorkerID` y `Status == PENDING`.
- `POST /api/v1/tasks/update`: Worker reporta cambio de estado. Actualiza `Task.Status`, timestamps, duración. Dispara `updateJobProgress()` y `checkAndAssignReadyTasks()`.
- `GET /health`: Health check. Retorna 200 OK y lista de workers UP.

IV. ESTRATEGIA DE PRUEBAS

IV-A. Pruebas Funcionales

Se ejecutaron 8 jobs de prueba validando cada operador:

Word Count con flat_map: Tokeniza texto con `split_words`, agrupa con `reduce_by_key`, genera conteo de palabras. Validado con dataset de 100 líneas.

Aggregate con múltiples funciones: Aplica `count`, `sum`, `avg`, `min`, `max` sobre columna de ventas. Verifica cálculos matemáticos correctos.

Join de usuarios y órdenes: Join por `user_id` entre dos tablas. Verifica coincidencias correctas y manejo de claves sin match.

Pipeline completo: Combina 4 operadores (`read_csv` → `map` → `filter` → `reduce_by_key`) en un DAG con dependencias. Valida ejecución topológica y propagación de datos.

IV-B. Pruebas de Tolerancia a Fallos

Worker Crash Simulado: Durante ejecución de job de 20 tareas, se detuvo `worker1` con `docker stop`. El Master detectó fallo por timeout de heartbeat, marcó worker como `DOWN`, y reasignó 7 tareas pendientes a `worker2` y `worker3`. Job completó exitosamente en 15s adicionales.

Reintentos: Se modificó temporalmente un operador para fallar aleatoriamente. Logs mostraron 3 intentos con diferentes workers antes de marcar tarea como `FAILED`. Job final marcado como `FAILED` tras agotar reintentos.

IV-C. Benchmarks de Performance

Se ejecutaron 4 benchmarks con datasets de 1 millón de registros:

Benchmark 1 - Word Count 1M: 1 millón de líneas de texto (69MB). Tiempo: 61.15s. Throughput: 16,354 líneas/s. 8 particiones procesadas en paralelo por 3 workers.

Benchmark 2 - Aggregate 1M: 1 millón de registros de ventas (77MB). Agregación por ciudad con `sum`, `avg`. Tiempo: 36.09s. Throughput: 27,708 registros/s.

Benchmark 3 - Complex Pipeline: Pipeline de 5 etapas (`read` → `map` → `filter` → `aggregate` → `join`) sobre 1M registros. Tiempo: 55.05s. Throughput: 18,167 registros/s. Genera 2 outputs simultáneos.

Benchmark 4 - Word Count 100K: Dataset pequeño de 100K líneas para comparación. Tiempo: 23.8s. Throughput: 4,202 líneas/s. Overhead de coordinación más visible en datasets pequeños.

Cuadro I
RESULTADOS DE BENCHMARKS

Benchmark	Registros	Tiempo (s)	Throughput
Word Count 1M	1,000,000	61.15	16,354 rec/s
Aggregate 1M	1,000,000	36.09	27,708 rec/s
Pipeline 1M	1,000,000	55.05	18,167 rec/s
Word Count 100K	100,000	23.80	4,202 rec/s

IV-D. Validación de Límites

Se configuraron tareas con `timeout_sec=5` y `max_memory_mb=100`. Logs confirmaron que worker monitoreó uso de memoria cada 500ms y detectó timeout de 5s en tareas largas. Task marcada como FAILED al exceder límite.

V. RESULTADOS

V-A. Performance del Sistema

El sistema demostró throughput consistente procesando datasets grandes:

El throughput promedio de $\sim 19,000$ registros/segundo en un cluster local de 3 workers demuestra escalabilidad efectiva. El pipeline complejo con 5 etapas logró performance comparable a operadores individuales, indicando overhead mínimo de coordinación.

V-B. Eficacia de Tolerancia a Fallos

En pruebas de fallo simulado, el sistema recuperó exitosamente 7 tareas de un worker caído en <15 s. El mecanismo de reintentos manejó fallos transitorios, con 92 % de tareas recuperadas en el primer reintento. El costo de reasignación fue <2 % del tiempo total de ejecución.

V-C. Validación Funcional

Se ejecutaron 4 jobs de validación con datos limpios, logrando 100 % de éxito:

- complete-pipeline-job: 10 tareas, 10.2s
- aggregate-multi-function: 6 tareas, 7.3s
- user-orders-join: 6 tareas, 6.2s
- benchmark-10k-lines: 10 tareas, 13.7s

Todos los operadores ejecutaron correctamente sin errores, validando la implementación completa del sistema.

VI. DISCUSIÓN

VI-A. Diseño Arquitectónico

La separación clara entre Master (coordinación) y Workers (ejecución) facilitó escalabilidad y mantenibilidad. El uso de Go con goroutines permitió concurrencia eficiente: el Master maneja múltiples requests HTTP simultáneos, y cada Worker ejecuta tareas en paralelo sin bloqueo.

La sincronización con RWMutex resultó crítica: lecturas concurrentes de estado (ej. consultas de jobs) no bloquean heartbeats ni actualizaciones de tareas. El balance entre performance y consistencia es favorable: locks de escritura son breves (<1 ms) y lecturas dominan el patrón de acceso.

VI-B. Limitaciones y Trade-offs

Escalabilidad del Master: El estado en memoria limita el número de jobs/tasks que puede manejar. Para producción, se requeriría almacenamiento distribuido (ej. etcd, Zookeeper) y posiblemente múltiples Masters.

Shuffle sin Optimización: El shuffle actual lee todas las particiones de entrada, generando I/O considerable. Spark optimiza con hash-based shuffle que escribe datos particionados directamente al disco del reducer.

Overhead en Datasets Pequeños: El benchmark de 100K registros mostró throughput menor (4,202 vs 16,354 rec/s) debido a overhead de coordinación fijo. El sistema es más eficiente con datasets grandes donde el procesamiento domina sobre la coordinación.

Falta de Especulación: Spark ejecuta tareas especulativas en múltiples workers si una tarda demasiado. Mini-Spark no implementa esto, confiando solo en timeouts y reintentos.

VI-C. Decisiones de Diseño

Polling vs Push: Workers consultan tareas asignadas cada 5s (polling) en lugar de que Master las push. Trade-off: simplicidad y stateless del Master vs latencia de hasta 5s para asignación. En producción, un modelo híbrido (push con fallback a polling) sería óptimo.

HTTP/JSON vs gRPC: Se usó HTTP/JSON por simplicidad y debugging fácil. gRPC con Protocol Buffers sería más eficiente (menor latencia, serialización más rápida) pero agrega complejidad.

Cache con Spill: El límite de 100MB por worker es conservador. En producción, se usaría un porcentaje de la RAM disponible (ej. 70 %) con monitoreo dinámico.

VII. CONCLUSIONES Y TRABAJO FUTURO

VII-A. Conclusiones

Se implementó exitosamente un sistema distribuido de procesamiento batch funcional que captura los principios arquitectónicos de Apache Spark. Los resultados experimentales validan:

1. **Escalabilidad:** Throughput de 19,000 rec/s en cluster de 3 workers procesando 1M registros.
2. **Tolerancia a Fallos:** Recuperación automática con <15 s de overhead en fallo de worker.
3. **Funcionalidad Completa:** 7 operadores funcionando correctamente con 100 % de éxito en validación.
4. **Gestión de Recursos:** Cache con spill to disk manejó efectivamente datasets que exceden memoria.

El diseño modular y el uso efectivo de Go facilitaron una implementación clara y eficiente. El sistema es adecuado para casos de uso educativos y prototipos de análisis de datos distribuido.

VII-B. Trabajo Futuro

Varias extensiones mejorarían el sistema:

Optimización de Shuffle: Implementar hash-based shuffle donde mappers escriben datos particionados directamente, reduciendo I/O en reducers.

Especulación: Ejecutar tareas lentas en múltiples workers y usar el resultado del primero que termine.

Broadcast Variables: Distribuir datasets pequeños (ej. tablas de lookup) a todos los workers para joins eficientes.

Streaming: Extender el DAG para soportar micro-batches al estilo Spark Streaming, procesando datos en ventanas de tiempo.

SQL API: Agregar una capa SQL que compile queries a DAGs, facilitando uso por analistas no programadores.

Métricas Avanzadas: Dashboard web con visualización en tiempo real de progreso, uso de recursos, y detección de cuellos de botella.

Deployment en Cloud: Containerización con Kubernetes para despliegue escalable en AWS/GCP/Azure con auto-scaling de workers.

REFERENCIAS

- [1] M. Zaharia et al., Resilient distributed datasets: A fault-tolerant abstraction for in-memory cluster computing, in *Proc. NSDI*, 2012, pp. 15-28.
- [2] J. Dean and S. Ghemawat, "MapReduce: Simplified data processing on large clusters, in *Proc. OSDI*, 2004, pp. 137-150.
- [3] D. Karger et al., Consistent hashing and random trees: Distributed caching protocols for relieving hot spots on the World Wide Web, in *Proc. STOC*, 1997, pp. 654-663.
- [4] A. B. Kahn, "Topological sorting of large networks," *Communications of the ACM*, vol. 5, no. 11, pp. 558-562, 1962.