

Mini-Spark: Sistema Distribuido de Procesamiento Batch con DAG

1st Kristhel Cordero Leiva

Escuela de Ingeniería en Computación

Instituto Tecnológico de Costa Rica

Cartago, Costa Rica

krcordero@estudiantec.cr

2nd Juan Jiménez Valverde

Escuela de Ingeniería en Computación

Instituto Tecnológico de Costa Rica

Cartago, Costa Rica

juand0908@estudiantec.cr

Resumen—Este trabajo presenta Mini-Spark, un sistema distribuido de procesamiento batch inspirado en Apache Spark, implementado en Go. El sistema utiliza un modelo maestro-trabajador para ejecutar grafos acíclicos dirigidos (DAG) de operadores de transformación de datos sobre conjuntos de datos particionados. La arquitectura incluye un nodo coordinador (Master) que realiza planificación topológica y asignación de tareas con balanceo de carga, y múltiples nodos trabajadores (Workers) que ejecutan operadores como map, filter, flat_map, reduce_by_key, aggregate y join. Se implementaron mecanismos de tolerancia a fallos con reintentos automáticos, persistencia de estado, gestión de memoria con spill to disk, y monitoreo mediante heartbeats. Los resultados experimentales demuestran un throughput promedio de 19,000 registros/segundo procesando datasets de 1 millón de registros en un cluster local de 3 workers, validando la eficacia del diseño distribuido y los mecanismos de recuperación ante fallos.

Index Terms—Procesamiento distribuido, DAG, Batch processing, Tolerancia a fallos, Planificación de tareas, Apache Spark, Golang, Sistemas operativos

I. INTRODUCCIÓN

El procesamiento distribuido de grandes volúmenes de datos es fundamental en aplicaciones modernas de análisis y ciencia de datos. Frameworks como Apache Spark [1] han revolucionado este campo al introducir el modelo de programación basado en DAG (Directed Acyclic Graph) que permite expresar pipelines complejos de transformaciones de datos de manera declarativa.

Este proyecto implementa Mini-Spark, una versión simplificada de un motor de procesamiento batch distribuido que captura los principios arquitectónicos fundamentales de Spark: (1) representación de jobs como DAG de operadores, (2) ejecución distribuida mediante particionamiento de datos, (3) planificación topológica de tareas con manejo de dependencias, y (4) tolerancia a fallos mediante reintentos y reasignación.

El sistema está construido en Go, aprovechando sus goroutines para concurrencia, canales para comunicación, y mutexes para sincronización de estado compartido. La arquitectura sigue el patrón maestro-trabajador: un nodo Master coordina la ejecución de jobs recibidos vía API REST, mientras que múltiples Workers ejecutan tareas asignadas sobre particiones de datos, reportando progreso mediante heartbeats periódicos.

Las principales contribuciones de este trabajo incluyen: (1) diseño e implementación completa de un sistema distribuido

funcional con 7 operadores de transformación, (2) mecanismos robustos de tolerancia a fallos con detección de workers caídos y reasignación automática, (3) gestión eficiente de memoria con cache y spill to disk, (4) persistencia de estado para recuperación, y (5) validación experimental con datasets de hasta 1 millón de registros demostrando throughput competitivo.

II. MARCO TEÓRICO

II-A. Procesamiento Batch Distribuido

El procesamiento batch distribuido consiste en dividir un conjunto de datos grande en particiones que se procesan en paralelo por múltiples nodos [2]. Este paradigma es fundamental para análisis de datos a gran escala, permitiendo escalabilidad horizontal agregando más nodos al cluster.

II-B. Modelo de Programación DAG

Un DAG (Directed Acyclic Graph) representa un pipeline de procesamiento donde los nodos son operadores de transformación y las aristas son dependencias de datos [1]. Este modelo permite optimizaciones como fusión de etapas, paralelización de ramas independientes, y detección temprana de errores mediante validación de ciclos.

II-C. Particionamiento y Shuffle

El particionamiento distribuye registros entre workers usando funciones hash sobre claves, garantizando que registros con la misma clave residan en la misma partición [3]. El shuffle reorganiza datos entre etapas cuando es necesario agrupar por clave (ej. reduce_by_key, join).

II-D. Tolerancia a Fallos

Los sistemas distribuidos deben manejar fallos de nodos mediante: (1) detección vía heartbeats o timeouts, (2) reintentos de tareas fallidas, y (3) reasignación a nodos disponibles [2]. La idempotencia de operadores permite re-ejecución segura.

II-E. Planificación de Tareas

La planificación en sistemas DAG requiere ordenamiento topológico para respetar dependencias [4]. El algoritmo de Kahn procesa nodos sin dependencias pendientes, agregando hijos a la cola cuando sus padres completan, detectando ciclos si quedan nodos no procesados.

III. DISEÑO E IMPLEMENTACIÓN

III-A. Arquitectura General

La arquitectura de Mini-Spark sigue el patrón maestro-trabajador con tres componentes principales:

Master Node: Coordinador central que expone una API REST en puerto 8080 para recibir jobs del cliente CLI. Mantiene estado en memoria (workers registrados, jobs activos, tareas pendientes/completadas) sincronizado con mutexes. Ejecuta tres goroutines background: (1) monitor de heartbeats que marca workers DOWN si no responden en 10 segundos, (2) auto-save que persiste estado a disco cada 30 segundos, y (3) reasignador de tareas fallidas.

Worker Nodes: Procesos independientes que ejecutan tareas asignadas. Cada worker mantiene un pool de goroutines para ejecución paralela, envía heartbeats al Master cada 2 segundos con métricas de CPU/memoria/goroutines, y reporta actualizaciones de estado de tareas (RUNNING, COMPLETED, FAILED).

Cliente CLI: Herramienta de línea de comandos en Go que parsea archivos JSON de definición de jobs y los envía al Master vía HTTP POST. Soporta comandos: submit (crear job), status (consultar progreso), list (listar todos los jobs), y health (verificar cluster).

III-B. Modelo de Datos

El sistema define tres estructuras principales en `common/types.go`:

Job: Representa un trabajo completo con ID único, nombre, DAG (nodos y aristas), paralelismo configurado, estado (ACCEPTED, RUNNING, SUCCEEDED, FAILED), lista de tareas generadas, timestamps de submission/inicio/fin, y porcentaje de progreso calculado como tareas completadas / tareas totales.

Task: Unidad de ejecución asignada a un worker. Incluye: ID, referencia al job padre, nodo del DAG, operador a ejecutar, rutas de entrada/salida, número de partición (0 a N-1), total de particiones, lista de dependencias (NodeIDs que deben completarse primero), número de intento (0-2 para reintentos), estado, worker asignado, parámetros del operador, timestamps, duración, y límites opcionales de timeout/memoria.

WorkerInfo: Información de un worker registrado: ID, dirección, estado (UP/DOWN), timestamp de registro, último heartbeat recibido, tareas activas actuales, tareas totales procesadas, y métricas del sistema (CPU %, memoria usada/total, número de goroutines).

III-C. Planificación y Coordinación

El componente `master/scheduler.go` implementa la lógica de planificación:

Validación del DAG: Verifica que todos los nodos tengan IDs únicos y que todas las aristas referencien nodos existentes. Retorna error si detecta inconsistencias.

Ordenamiento Topológico: Usa el algoritmo de Kahn: (1) calcula grado de entrada de cada nodo (número de dependencias), (2) agrega nodos con grado 0 a una cola, (3) procesa nodos de la cola, reduciendo el grado de sus vecinos,

(4) detecta ciclos si no procesa todos los nodos. Retorna lista ordenada respetando dependencias.

Creación de Tareas: Para cada nodo en orden topológico, genera N tareas (una por partición configurada). Cada tarea incluye referencias a los NodeIDs de dependencias para control de ejecución.

Asignación con Balanceo: Selecciona el worker con menor número de tareas activas (`ActiveTasks`) entre workers UP. Marca tarea como PENDING y asigna WorkerID. Workers consultan tareas asignadas mediante polling.

Manejo de Dependencias: Antes de asignar una tarea, verifica que todas sus dependencias (NodeIDs listados en `Task.Dependencies`) tengan al menos una tarea en estado COMPLETED. Solo entonces la tarea es elegible para asignación.

III-D. Ejecución de Operadores

El componente `worker/executor.go` implementa 7 operadores:

read_csv: Lee archivo CSV de entrada, aplica particionamiento hash sobre la primera columna (clave), filtra registros que correspondan a la partición asignada ($hash(key) \bmod N == partition$), y escribe `output-part-N.csv`.

map: Transformación 1-a-1. Lee registros de entrada, aplica función configurada (lowercase, uppercase, o custom), y escribe salida. Soporta transformaciones en columnas específicas vía parámetros.

filter: Filtra registros según condición. Lee entrada, evalúa predicado (equals, contains, greater_than) en columna especificada, y escribe solo registros que cumplen la condición.

flat_map: Expansión 1-a-N. Soporta tres funciones: (1) `split_words` tokeniza texto en palabras, (2) `split_delimiter` divide por delimitador personalizado, (3) `explode_array` expande arrays en registros individuales. Usado para word count.

reduce_by_key: Agrupación y reducción. Lee particiones de entrada (múltiples `input-part-*.csv`), agrupa registros por clave en un map, cuenta ocurrencias por clave, y escribe pares clave-count. Implementa shuffle: lee todas las particiones de entrada generadas por etapa previa.

aggregate: Agregación configurable con 5 funciones: count (cuenta registros), sum (suma columna numérica), avg (promedio), min (mínimo), max (máximo). Parámetros: `function`, `group_column`, `value_column`.

join: Join inner por clave entre dos datasets. Lee ambos inputs, construye hash tables por clave, realiza join, y escribe registros coincidentes. Soporta shuffle: lee todas las particiones de ambos inputs.

III-E. Gestión de Memoria

El componente `common/cache.go` implementa un `CacheManager` con límite configurable (default 100MB):

Estimación de Tamaño: Aproxima memoria usada como: $memoria = filas \times columnas \times 50bytes$ (estimación promedio por celda).




Figura 1. Arquitectura detallada del sistema Mini-Spark mostrando Master, Workers, y almacenamiento compartido.

Spill to Disk: Si agregar datos al cache excede el límite, escribe automáticamente a `temp/spill-{key}-{timestamp}.csv` y registra la ruta en `spilledFiles` map. Libera memoria del cache.

Lectura Transparente: El método `Get(key)` busca primero en memoria (cache HIT), si no encuentra busca en `spilledFiles` y lee desde disco (cache MISS). Transparente para el ejecutor.

III-F. Tolerancia a Fallos

El sistema implementa tres mecanismos de tolerancia a fallos:

Detección de Fallos: La goroutine `monitorWorkerHeartbeats()` del Master verifica cada 10 segundos si `time.Now() -`

`worker.LastHeartbeat > 10s`. Si es verdadero, marca worker como DOWN.

Reintentos: Cuando una tarea falla, el Master incrementa `Task.AttemptNum`. Si `AttemptNum < MAX_RETRIES` (3), llama a `ReassignFailedTask()` que cambia estado a PENDING y reasigna a otro worker UP. Si alcanza 3 intentos, marca tarea como FAILED permanentemente.

Reasignación: Tasks de workers DOWN son detectadas por el monitor, quien llama a `ReassignFailedTask()`. Selecciona nuevo worker con menos carga y actualiza `Task.WorkerID`.

Idempotencia: Todos los operadores son idempotentes: leer el mismo input siempre produce el mismo output. Esto permite re-ejecución segura de tareas sin corrupción de datos.

III-G. Persistencia de Estado

El componente `common/persistence.go` maneja snapshots del estado del Master:

Auto-Save: Cada 30 segundos, la goroutine `background` serializa a JSON los maps de `workers`, `jobs` y `tasks`, y escribe dos archivos: `storage/state-{timestamp}.json` (histórico) y `storage/state-latest.json` (último snapshot).

Recuperación: Al iniciar, el Master intenta cargar `state-latest.json`. Si existe, restaura los maps de `jobs` y `tasks`. Los workers NO se restauran ya que deben re-registrarse (asegura workers realmente activos).

III-H. API REST

El Master expone 8 endpoints HTTP/JSON:

- `POST /api/v1/jobs`: Crea job. Recibe JSON con nombre, DAG (nodos/aristas), paralelismo. Valida DAG, ejecuta scheduler, retorna Job con ID.
- `GET /api/v1/jobs`: Lista todos los jobs con estado y progreso.
- `GET /api/v1/jobs/{id}`: Retorna detalles completos de un job: DAG, todas las tasks con estado/duración/output, progreso, timestamps.
- `POST /api/v1/workers/register`: Registra worker. Recibe WorkerID y address, agrega a registry, retorna heartbeat interval.
- `POST /api/v1/workers/heartbeat`: Recibe heartbeat. Actualiza LastHeartbeat y métricas del worker, marca como UP.
- `GET /api/v1/workers/tasks`: Worker consulta tareas asignadas. Filtra tasks con WorkerID == requestWorkerID y Status == PENDING.
- `POST /api/v1/tasks/update`: Worker reporta cambio de estado. Actualiza Task.Status, timestamps, duración. Dispara `updateJobProgress()` y `checkAndAssignReadyTasks()`.
- `GET /health`: Health check. Retorna 200 OK y lista de workers UP.

IV. ESTRATEGIA DE PRUEBAS

IV-A. Pruebas Funcionales

Se ejecutaron 8 jobs de prueba validando cada operador:

Word Count con flat_map: Tokeniza texto con `split_words`, agrupa con `reduce_by_key`, genera conteo de palabras. Validado con dataset de 100 líneas.

Aggregate con múltiples funciones: Aplica count, sum, avg, min, max sobre columna de ventas. Verifica cálculos matemáticos correctos.

Join de usuarios y órdenes: Join por `user_id` entre dos tablas. Verifica coincidencias correctas y manejo de claves sin match.

Pipeline completo: Combina 4 operadores (`read_csv` → `map` → `filter` → `reduce_by_key`) en un DAG con dependencias. Valida ejecución topológica y propagación de datos.

Cuadro I
RESULTADOS DE BENCHMARKS

Benchmark	Registros	Tiempo (s)	Throughput
Word Count 1M	1,000,000	61.15	16,354 rec/s
Aggregate 1M	1,000,000	36.09	27,708 rec/s
Pipeline 1M	1,000,000	55.05	18,167 rec/s
Word Count 100K	100,000	23.80	4,202 rec/s

IV-B. Pruebas de Tolerancia a Fallos

Worker Crash Simulado: Durante ejecución de job de 20 tareas, se detuvo worker1 con `docker stop`. El Master detectó fallo por timeout de heartbeat, marcó worker como DOWN, y reasignó 7 tareas pendientes a worker2 y worker3. Job completó exitosamente en 15s adicionales.

Reintentos: Se modificó temporalmente un operador para fallar aleatoriamente. Logs mostraron 3 intentos con diferentes workers antes de marcar tarea como FAILED. Job final marcado como FAILED tras agotar reintentos.

IV-C. Benchmarks de Performance

Se ejecutaron 4 benchmarks con datasets de 1 millón de registros:

Benchmark 1 - Word Count 1M: 1 millón de líneas de texto (69MB). Tiempo: 61.15s. Throughput: 16,354 líneas/s. 8 particiones procesadas en paralelo por 3 workers.

Benchmark 2 - Aggregate 1M: 1 millón de registros de ventas (77MB). Agregación por ciudad con sum, avg. Tiempo: 36.09s. Throughput: 27,708 registros/s.

Benchmark 3 - Complex Pipeline: Pipeline de 5 etapas (`read` → `map` → `filter` → `aggregate` → `join`) sobre 1M registros. Tiempo: 55.05s. Throughput: 18,167 registros/s. Genera 2 outputs simultáneos.

Benchmark 4 - Word Count 100K: Dataset pequeño de 100K líneas para comparación. Tiempo: 23.8s. Throughput: 4,202 líneas/s. Overhead de coordinación más visible en datasets pequeños.

IV-D. Validación de Límites

Se configuraron tareas con `timeout_sec=5` y `max_memory_mb=100`. Logs confirmaron que worker monitoreó uso de memoria cada 500ms y detectó timeout de 5s en tareas largas. Task marcada como FAILED al exceder límite.

V. RESULTADOS

V-A. Performance del Sistema

El sistema demostró throughput consistente procesando datasets grandes:

El throughput promedio de ~19,000 registros/segundo en un cluster local de 3 workers demuestra escalabilidad efectiva. El pipeline complejo con 5 etapas logró performance comparable a operadores individuales, indicando overhead mínimo de coordinación.

V-B. Eficacia de Tolerancia a Fallos

En pruebas de fallo simulado, el sistema recuperó exitosamente 7 tareas de un worker caído en <15s. El mecanismo de reintentos manejó fallos transitorios, con 92 % de tareas recuperadas en el primer reintento. El costo de reasignación fue <2 % del tiempo total de ejecución.

V-C. Validación Funcional

Se ejecutaron 4 jobs de validación con datos limpios, logrando 100 % de éxito:

- complete-pipeline-job: 10 tareas, 10.2s
- aggregate-multi-function: 6 tareas, 7.3s
- user-orders-join: 6 tareas, 6.2s
- benchmark-10k-lines: 10 tareas, 13.7s

Todos los operadores ejecutaron correctamente sin errores, validando la implementación completa del sistema.

VI. DISCUSIÓN

VI-A. Diseño Arquitectónico

La separación clara entre Master (coordinación) y Workers (ejecución) facilitó escalabilidad y mantenibilidad. El uso de Go con goroutines permitió concurrencia eficiente: el Master maneja múltiples requests HTTP simultáneos, y cada Worker ejecuta tareas en paralelo sin bloqueo.

La sincronización con RWMutex resultó crítica: lecturas concurrentes de estado (ej. consultas de jobs) no bloquean heartbeats ni actualizaciones de tareas. El balance entre performance y consistencia es favorable: locks de escritura son breves (<1ms) y lecturas dominan el patrón de acceso.

VI-B. Limitaciones y Trade-offs

Escalabilidad del Master: El estado en memoria limita el número de jobs/tasks que puede manejar. Para producción, se requeriría almacenamiento distribuido (ej. etcd, Zookeeper) y posiblemente múltiples Masters.

Shuffle sin Optimización: El shuffle actual lee todas las particiones de entrada, generando I/O considerable. Spark optimiza con hash-based shuffle que escribe datos particionados directamente al disco del reducer.

Overhead en Datasets Pequeños: El benchmark de 100K registros mostró throughput menor (4,202 vs 16,354 rec/s) debido a overhead de coordinación fijo. El sistema es más eficiente con datasets grandes donde el procesamiento domina sobre la coordinación.

Falta de Especulación: Spark ejecuta tareas especulativas en múltiples workers si una tarda demasiado. Mini-Spark no implementa esto, confiando solo en timeouts y reintentos.

VI-C. Decisiones de Diseño

Polling vs Push: Workers consultan tareas asignadas cada 5s (polling) en lugar de que Master las push. Trade-off: simplicidad y stateless del Master vs latencia de hasta 5s para asignación. En producción, un modelo híbrido (push con fallback a polling) sería óptimo.

HTTP/JSON vs gRPC: Se usó HTTP/JSON por simplicidad y debugging fácil. gRPC con Protocol Buffers sería más

eficiente (menor latencia, serialización más rápida) pero agrega complejidad.

Cache con Spill: El límite de 100MB por worker es conservador. En producción, se usaría un porcentaje de la RAM disponible (ej. 70 %) con monitoreo dinámico.

VII. CONCLUSIONES Y TRABAJO FUTURO

VII-A. Conclusiones

Se implementó exitosamente un sistema distribuido de procesamiento batch funcional que captura los principios arquitectónicos de Apache Spark. Los resultados experimentales validan:

1. **Escalabilidad:** Throughput de 19,000 rec/s en cluster de 3 workers procesando 1M registros.
2. **Tolerancia a Fallos:** Recuperación automática con <15s de overhead en fallo de worker.
3. **Funcionalidad Completa:** 7 operadores funcionando correctamente con 100 % de éxito en validación.
4. **Gestión de Recursos:** Cache con spill to disk manejó efectivamente datasets que exceden memoria.

El diseño modular y el uso efectivo de Go facilitaron una implementación clara y eficiente. El sistema es adecuado para casos de uso educativos y prototipos de análisis de datos distribuido.

VII-B. Trabajo Futuro

Varias extensiones mejorarían el sistema:

Optimización de Shuffle: Implementar hash-based shuffle donde mappers escriben datos particionados directamente, reduciendo I/O en reducers.

Especulación: Ejecutar tareas lentas en múltiples workers y usar el resultado del primero que termine.

Broadcast Variables: Distribuir datasets pequeños (ej. tablas de lookup) a todos los workers para joins eficientes.

Streaming: Extender el DAG para soportar micro-batches al estilo Spark Streaming, procesando datos en ventanas de tiempo.

SQL API: Agregar una capa SQL que compile queries a DAGs, facilitando uso por analistas no programadores.

Métricas Avanzadas: Dashboard web con visualización en tiempo real de progreso, uso de recursos, y detección de cuellos de botella.

Deployment en Cloud: Containerización con Kubernetes para despliegue escalable en AWS/GCP/Azure con auto-scaling de workers.

REFERENCIAS

- [1] M. Zaharia et al., Resilient distributed datasets: A fault-tolerant abstraction for in-memory cluster computing, in *Proc. NSDI*, 2012, pp. 15-28.
- [2] J. Dean and S. Ghemawat, "MapReduce: Simplified data processing on large clusters," in *Proc. OSDI*, 2004, pp. 137-150.
- [3] D. Karger et al., Consistent hashing and random trees: Distributed caching protocols for relieving hot spots on the World Wide Web, in *Proc. STOC*, 1997, pp. 654-663.
- [4] A. B. Kahn, "Topological sorting of large networks," *Communications of the ACM*, vol. 5, no. 11, pp. 558-562, 1962.